

单神经元

有两个著名的单神经元模型


- 1907年提出的Integrate and Fire model
- 1952年提出的Hodgkin-Huxley model

Integrate and Fire model

用下图所示的1个常微分方程描述神经元

$$\begin{cases} C_m \frac{dV_m(t)}{dt} = I(t) - g_{leak}(V_m(t) - V_{leak}) \\ V(t_{spike}^-) = V_{threshold} \\ V(t_{spike}^+) = V_{resting} \end{cases}$$

下图是它的解析解





Hodgkin-Huxley model

用下图所示的4个常微分方程描述神经元

$$\begin{cases} I = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l) \\ \frac{dn}{dt} = \alpha_n(V_m)(1 - n) - \beta_n(V_m)n \\ \frac{dm}{dt} = \alpha_m(V_m)(1 - m) - \beta_m(V_m)m \\ \frac{dh}{dt} = \alpha_h(V_m)(1 - h) - \beta_h(V_m)h \end{cases}$$

下图是它的数值解



take home point

- HH model is a **biological plausible** model.
 - HH model 是一个生物学合理的模型，这一点是非常难以做到的。它准确地描述了能斯特电势、离子通道、漏电导。几乎就没有几个模型是公认的biological plausible的。Hodgkin和Huxley也因此拿了诺贝尔奖。
 - 现在的神经网络都是biological implausible的，BP算法也是biological implausible的。很多人都希望做出一个biological plausible neural network。
- Integrate and Fire model是一个简化版的HH model，它用两个强加的条件代替了HH model中的后三个微分方程。
- HH model 只有数值解，没有解析解。Integrate and Fire model有解析解。

- 这两个model直到今天都还有人在用。很多组在HH model上加上各种各样的修正项来更好地模拟单神经元（但这些都是些边边角角修修补补的工作了）。Integrate and Fire model还没被抛弃是因为它形式简单而且有解析解。想了解他们的现状可以读读这两篇：[HH model](#)、[Integrate and Fire model](#)。

从单神经元到多神经元

在多神经元/神经网络中，我们不能对每个神经元都去解Integrate and Fire model或者Hodgkin-Huxley model这样的常微分方程，计算量太大了。

为了简化问题，我们不再画上面那样的V-t图，而是动作电位频率（firing rate，记为 r ）来作为1个神经元的指标。

也就是说，1个数即1个神经元。

我们忽略了不同的动作电位之间的差异，认为它们都是相同的，这个简化应该是可以接受的。

我们有两种方法来描述某个神经元的动作电位频率的演化。

第一种是动态的，用一个常微分方程来描述：

$$\tau \frac{dr}{dt} = -r + \vec{w} \cdot \vec{x}$$

其中， $\vec{w} \cdot \vec{x}$ 是其它所有和它有突触连接的神经元给它的输入。

第二种是静态的

$$r = \vec{w} \cdot \vec{x}$$

显然，第二种描述方法即第一种的稳态。


在计算神经科学中，我们有时候用前者（比如ring network那道作业题），有时候用后者，这取决于我们想研究什么问题。

在计算机神经网络中，学者们通常都用后者，以减少计算量。

温老师上课讲的时候都没有考虑偏置项 b ，也可以把 b 考虑进去。只不过公式会复杂一些。

下一节我简单介绍一下计算机神经网络。

计算机神经网络



该图的意义：

- 每一个小圆圈代表一个神经元。
- 我们用每一个神经元的firing rate（动作电位频率，大于0）作为这个神经元活跃程度的表征。即，一个小圆圈对应一个神经元对应一个正数。
- 每一层和下一层之间有一个“突触”，代表连接权重，在图中我用红笔和蓝笔花了两个示例（ W_{ji} 和 W_{kj} ），这个数可正可负，正数代表激励型突触，负数代表抑制性突触。即，一条连线对应一个突触对应一个数。
- input layer用来接收输入。比如说，咱们在lab5中，假如把4个特征扔进神经网络里，上图中的input layer的四个圆圈就会接收它们。如果扔进去120个特征，就需要input layer有120个神经元。
- hidden layer可以从几层到几千层。
- output layer用来输出。比如说，咱们在lab5中只有1个label，那就只有一个输出。如果有2个label，输出层就有2个神经元。

这个模型受启发于人类视网膜，人类视网膜显现出这样的分层结构，一共有10层。（人工神经网络和生物神经网络的关系类似于飞机和鸟的关系，前者最开始都受后者的启发但前者和后者相似的地方其实很少）

这个模型叫前馈神经网络(feedforward neural network)，因为这里“动作电位”只能一层一层向前传递，不能从下一层返还到上一层。

前馈神经网络和residue neural network很类似，后者只是小改了一些东西。


第n层和第n+1层之间的关系是

$$\vec{x}_{n+1} = F(W\vec{x}_n)$$

其中：

- $\vec{x}_n$ 为第n层的动作电位频率。它的第i个分量为第n层第i个神经元的动作电位频率。
- W为连接矩阵。比如说， W_{ji} 代表第n层的第i个神经元和第n+1层的第j个神经元之间的连接。
- **F(x)为ReLU function或Sigmoid type function。它的存在是为了防止神经元的动作电位频率小于0或趋于无穷。**

最后提一下神经网络和线性模型的联系



上图这样的只有2层且第二层只有一个神经元的神经网络也称为感知机。

把第二层的神经元的动作电位频率设为 y 。

当 $F(x) = x$ 时, $y = \vec{w} \cdot \vec{x}$, 和普通线性回归的公式一模一样。

当 $F(x) = \frac{1}{1+e^{-x}}$ 时, $y = \frac{1}{1+e^{-\vec{w} \cdot \vec{x}}}$, 和对数几率回归的公式一模一样。

Error-back propagation

前馈神经网络用著名的Error-back propagation训练:

$$Error := 1/2 * \sum_k (y_k - label_k)^2$$

其中, y_k 为预测值, $label_k$ 为真实值

每一个权重的更新公式为

$$w_{ji}^{t+1} = w_{ji}^t - \eta \cdot \delta_j \cdot r_i$$

其中

- η 为学习率, 是一个超参数。
- r_i 为第 i 个神经元的动作电位频率, r 是从第一层开始往后一层层正向传播的。
 - 第一层的 r 就是你给的输入
- $\delta_j := \frac{\partial Error}{\partial I_j}$, where $I_j := \sum_i W_{ji} r_i$, δ 是从最后一层开始往前一层一层反向传播的。
 - 最后一层的 δ 为: $\delta = (y - \tilde{y}) F'$

r 是从第一层开始往后一层层正向传播的, 很显然。

δ 是从最后一层开始往前一层一层反向传播的, 不那么显然, 但是经过一番细致的推导, 我们可以得到

$$\delta_j^{(l)} = \sum_k \delta_k^{(l+1)} w_{kj} F'$$

上标代表层数。因此, $\delta_j^{(l)}$ 是 $\delta_k^{(l+1)}$ 的加权平均。


BP算法的biological implausible之处

- 轴突是单向的，信号只能一层一层正向传播，不可能一层一层反向传播
- 高等生物的神经元连出去的所有突触通常要么全都是兴奋性的要么是全都是抑制性的

一种相对来说比较biological plausible的模型是

$$\frac{dw_{ji}}{dt} = r_j u_i$$

它符合心理学家Hebb发现的规律。(Image from *Principle of Neuroscience*, Liqun Luo)



Impressive homework

- Visualization of Pukinje cell
- Simulation of Hodgkin-Huxley model
- Using functional derivative to prove some theorems
- Ring Network
- Hopfield Network
- E-I Network